RL-дообучение GPT-2 рекомендера на KION

T-Lab 2026 · RecSys · Задание 2

Коротко

Обучили GPT-2 предсказывать следующий объект по истории просмотров KION, построили две модели вознаграждения (reward model) для доли досмотра и дообучили рекомендер с помощью RL: GRPO с точным KL к исходной модели, AWR, DPO/IPO, Best-of-N и CRR с критиком на логах, всего 87 прогонов с десятью вариантами награды. Для каждой награды дополнительно посчитан аналитический оптимум, чтобы отделить ограничения оптимизатора от ограничений самой награды.

- **Базовая модель** на тестовой неделе даёт NDCG@10 0.136 против 0.131 у популярности (разница значима) и покрывает 28% каталога против 0.3%.
- **Reward model** предсказывает долю досмотра лишь немного лучше, чем средний досмотр объекта (Spearman 0.416 против 0.373). Почти весь сигнал - на уровне объекта (длина, средний досмотр). Признаки пользователя (RM-P) поднимают общий Spearman до 0.478, а Spearman внутри пользователя - лишь на 0.013 (0.348 против 0.335); RL с RM-P значимого выигрыша не даёт.
- **RL максимизирует награду, но через хакинг, предсказанный в условии.** Награда «доля досмотра» уводит рекомендации в короткий контент: средняя длительность падает с 5.4 до 3.4–3.8 ч, доля сериалов - с 34% до 18–22%, NDCG@10 значимо падает на 5–10%. При малом β модель схлопывается на десяток объектов.
- **Оптимизатор не узкое место.** GRPO берёт 97–98% прироста награды, доступного при том же KL. Компромисс «релевантность против награды» задаёт форма награды, а не алгоритм.
- **Награды на времени просмотра держат релевантность.** С наградой «доля × часы» и с наградой «склонность × часы» NDCG@10 теряет не больше 1.3% (у «склонность × часы» значимого отличия от базовой модели нет), а при уменьшении β релевантность падает намного медленнее. На тесте отбора ни одна модель с RM не улучшила proxy длительности номинально значимо на топ-10 (на топ-50 - только GRPO R9, +1%); на свежих пользователях прирост R9 подтверждается.
- **Проверка на свежих пользователях.** Тест отбора использовался многократно, поэтому трёх финальных кандидатов мы один раз оценили на 81 тыс. пользователей тестовой недели, которых ни разу не смотрели. AWR, взвешенный длительностью из логов без reward model, подтвердился: proxy +2.6%, NDCG@10 и @50 тоже значимо растут. CRR с критиком на часах одного шага даёт больший proxy (+5.7%), но за счёт сдвига в длинный контент и со значимой потерей NDCG и Recall. GRPO R9 даёт небольшой подтверждённый прирост proxy (+0.9%) без потери релевантности. Многошаговый CRR ($\gamma = 0.9$) в нашей реализации теряет 9% proxy на тесте отбора.

Подробные результаты - в разделе 4 (проверка на свежих пользователях - в 4.4, персональная reward model - в 4.6, полные таблицы - в приложении), разбор поведения - в разделе 5, выводы - в разделе 6.

1. Изучили данные и поставили задачу

Что в данных. MTS KION, тот же архив, что в задании 1: одна строка - агрегат пары user–item с датой *последнего* просмотра, суммарной длительностью `total_dur` и долей досмотра `watched_pct`. Отсюда несколько следствий для постановки:

1. **Последовательность восстанавливается приблизительно.** История пользователя - его объекты, упорядоченные по дате последнего просмотра; порядок внутри одного дня неизвестен и задан случайно. Повторных просмотров нет.
2. **Отклик - это доля досмотра.** Других откликов (лайков, оценок) нет, поэтому reward model предсказывает `watched_pct`. У сериалов она суммарная по всем сериям.

3. **Длительность объекта не дана.** Мы оцениваем её как медиану `total_dur / watched_pct` по просмотрам объекта; она нужна для наград «в часах».
4. **Показов и отказов нет.** Мы видим только то, что пользователь выбрал сам при старой системе. Это ограничивает и reward model, и любую офлайн-оценку долгосрочного эффекта (раздел 5.5).

Сплит по времени.

	Период	Что используется
Обучение	события до 09.08.2021	словарь, базовая модель, reward model, контексты для RL
Валидация	неделя 09.08–15.08	ранняя остановка, выбор β, наград и методов
Тест	**неделя 16.08–22.08**	итоговое сравнение

- **Последовательности:** 850 тыс. пользователей, 5.19 млн событий. Словарь - 9 999 объектов, у которых в обучении не меньше 5 взаимодействий, плюс служебные токены; доля событий вне словаря 0.7%. Контекст - последние 50 объектов.
- **Цель** - все объекты, которые пользователь смотрел в целевую неделю; уже просмотренное из рекомендаций исключается.
- **Оценка** на 10 тыс. случайных пользователей с историей и хотя бы одной целью, отдельно для валидации и теста.
- Тест задумывался как однократный, но к нему возвращались несколько раз (финалисты, варианты награды, диагностика). Поэтому это ретроспективно использованная отложенная выборка, а не нетронутая, и пограничные эффекты на ней - гипотезы.

Метрики.

- **Релевантность:** Recall@10, NDCG@10, MAP@10.
- **Поведение:** покрытие каталога, доля показов 10 самых частых объектов, популярность, средняя длительность рекомендаций, доля сериалов, жанровое разнообразие, пересечение топ-10 с базовой моделью (Jaccard).
- **Награда:** по reward model, на которой шло обучение (RM-A), и по независимой RM-B - в доле досмотра и в часах (доля × длительность).
- **Длительность совпавших рекомендаций (офлайн-proxy).** Для рекомендованных объектов, которые пользователь действительно посмотрел в целевую неделю, суммируется `total_dur` агрегата (не больше 5 ч на объект). Это попадание, взвешенное длительностью, а не недельное потребление: какая часть длительности пришлась на эту неделю, в KION не восстановить. Зато proxy не зависит ни от одной reward model.
- **Интервалы** - парный bootstrap по пользователям для разниц с базовой моделью.

2. Обучили базовую модель GPT-2

Модель. GPT-2 с токенами-объектами: 2 слоя, 2 головы внимания, эмбеддинги размерности 128, dropout 0.1, около 1.7 млн параметров. Обучение на next-item prediction по всем позициям всех последовательностей обучения (859 тыс. окон), AdamW, ранняя остановка по NDCG@10 на валидации. Лучшая эпоха - 12-я, NDCG@10 на валидации 0.153. Рекомендации - 10 объектов с наибольшей вероятностью среди непросмотренных. Дальше эта модель называется SFT и служит точкой отсчёта и референсной политикой π_{ref} для RL.

Результат на тесте.

Модель	Recall@10	NDCG@10	MAP@10	Покрытие	Доля топ-10 объектов	Длительность, ч	Сериалы
Popular	0.202	0.131	0.089	0.3%	0.84	4.9	47%
SFT	0.195	**0.136**	**0.095**	**28%**	0.42	5.4	34%

SFT лучше популярности по NDCG@10 на 0.005 [0.001; 0.009], а по Recall@10 немного уступает: в недельном горизонте популярные объекты часто попадают в цели, но SFT ставит попадания выше в списке. Главное отличие - персонализация: SFT покрывает 28% каталога, популярность - 0.3%.

3. Построили reward model

Reward model должна предсказывать отклик пользователя на объект с учётом истории. Отклик - доля досмотра.

RM-A - модель, на которой идёт RL. Это трансформер, инициализированный весами SFT, с MLP-головой над скрытым состоянием истории h, эмбеддингом объекта e и их произведением h·e. Обучается на парах «история - следующий объект» с бинарной кросс-энтропией к `watched_pct`. К ней добавлены головы, нужные для разных наград:

- **возврат:** вероятность, что пользователь посмотрит что-то ещё в следующие 7 дней;
- **score склонности:** классификатор «наблюдаемый объект против 8 случайных объектов каталога». Это не откалиброванная вероятность просмотра (случайный объект - не наблюдённый отказ), а ранжирующий сигнал «насколько этот объект похож на то, что пользователь выбирает». Два варианта: позитив - следующий объект (для R8) или случайный объект из ближайших 7 дней (для R9; окно обрезается на границе обучения, чтобы не захватить валидационные просмотры);
- **ансамбль** из трёх RM-A для пессимистичной награды R6.

RM-B - независимая модель только для оценки: LightGBM на признаках пользователя, объекта и их связи на момент cutoff, обучена на двух неделях до конца обучения (476 тыс. строк). Если RL хакает именно ошибки RM-A, RM-B этого прироста не подтвердит.

Качество на отложенной валидационной неделе (27 тыс. строк):

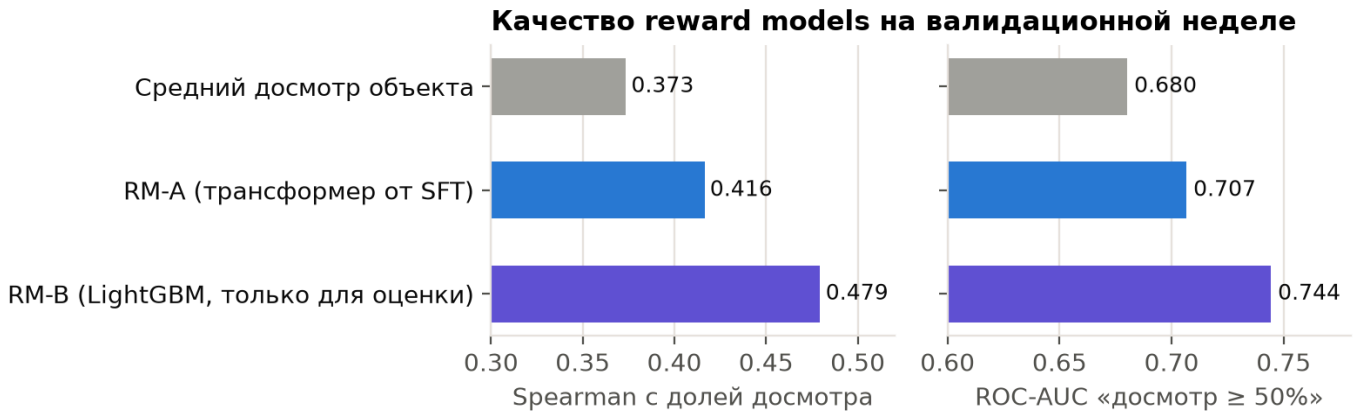


Рисунок 1. Spearman с долей досмотра и ROC-AUC для порога «досмотр ≥ 50%».

Модель	Spearman	ROC-AUC (досмотр ≥ 50%)	MAE
Средний досмотр объекта	0.373	0.680	0.322
RM-A	0.416	0.707	0.311
RM-B	0.479	0.744	0.297

- **Основная часть предсказательной силы - на уровне объекта.** Простое среднее досмотра объекта уже даёт 0.373, а RM-A добавляет к нему немного. Короткие фильмы досматривают чаще, и обе модели это выучили - именно это свойство RL потом и эксплуатирует.
- **Головы для других наград:** возврат за 7 дней предсказывается слабо (ROC-AUC 0.684), score склонности отличает наблюдаемый объект от случайного хорошо (ROC-AUC 0.94 и 0.95).

4. Дообучили модель с помощью RL

4.1. Постановка RL

Почему только офлайн RL. У нас есть только логи KION, а доступа к живым пользователям нет. Поэтому все методы, которым нужна обратная связь на собственные рекомендации модели, недоступны: контекстные бандиты (LinUCB, Thompson sampling), онлайн-исследование вроде ε-greedy, on-policy RL на реальных откликах, interleaving и A/B-тесты. Корректная off-policy оценка по логам тоже невозможна, потому что в KION нет показов и вероятностей показа. Остаётся офлайн RL: политика учится на исторических контекстах, а отклик на новые рекомендации заменяет обученная reward model. Отсюда главное ограничение всей работы: RL оптимизирует оценку reward model, а не реальную реакцию пользователей, и её ошибки становятся целью оптимизации (раздел 5.1).

Задача одношаговая. Состояние - история пользователя, действие - один объект из словаря, награда - отклик по RM-A. Политика инициализируется SFT. Поскольку действие одно, KL(π‖π_ref) можно посчитать точно по всему словарю, а не оценивать по сэмплам.

Награды. Каждая следующая награда отвечала на проблему предыдущей.

	Формула	**Зачем**
R1	$\hat{w}p$ - предсказанная доля досмотра	базовая награда из условия
R2	$\hat{w}p$ + 0.05 · log π_ref	поправка на релевантность
R3	$\hat{w}p$ × длительность (ч, не больше 3)	время вместо доли, против ухода в короткое
R4	вероятность возврата за 7 дней	шаг к долгосрочной цели
R5	$\hat{w}p$ - средний $\hat{w}p$ объекта	остаток относительно среднего досмотра объекта (грубая попытка выделить персональную часть, см. 5.1)
R6	пессимизм по ансамблю RM-A + log π_ref - штраф за схлопывание в батче	награда, которую трудно хакнуть
R7 / R7α	π_ref^α × $\hat{w}p$ × часы	склонность через саму SFT, умноженная на ценность
R8	$\hat{s}$ × $\hat{w}p$ × часы, $\hat{s}$ - score склонности (следующий объект)	эвристика «ожидаемого времени»
R8log	$\hat{s}$ × log(1 + $\hat{w}p$ × часы)	убывающая ценность часа
R9	как R8, но $\hat{s}$ обучен на окне 7 дней	ближе к метрике целевой недели

Награды R7–R9 появились после того, как стало видно, что $\hat{w}p$ условна на просмотр: RM-A предсказывает, насколько пользователь досмотрит объект, *если начнёт*, но ничего не говорит о том, начнёт ли он вообще. Умножение на склонность превращает награду в грубую оценку ожидаемого времени просмотра.

Методы.

- **GRPO:** для каждого контекста сэмплируется группа из 8 объектов, advantage - отклонение награды от среднего по группе с нормировкой по батчу, штраф β · KL(π‖π_ref) считается точно. 4 000 шагов, батч 256, lr 3e-5, dropout во время RL выключен (иначе KL не опускается ниже шума).
- **AWR:** SFT на логах с весами по доле досмотра или по длительности из логов, (1 + часы)^γ. Последний вариант не использует reward model вовсе.
- **CRR** (по схеме «GPT-2 + критик + CRR» из работы Integrating Offline RL with Transformers for Sequential Recommendation): отдельный критик Q(s, a) обучается на логах, затем SFT дообучается взвешенной кросс-энтропией на реальных следующих объектах с весом exp(A/β), A = Q(s, a) − Σ π(a'|s) Q(s, a'). Подробности и результаты - в разделе 4.5.
- **DPO и IPO** на парах «высокий и низкий досмотр» среди реальных следующих объектов.
- **Best-of-N:** дообучение SFT на лучшем из N сэмплов по награде.

- **GRPO + CE на логах:** к RL добавлена кросс-энтропия на реальных следующих объектах, как PTX в RLHF.
- **Аналитический оптимум.** Для одношаговой задачи с KL-штрафом оптимальная политика известна точно: π*_β ∝ π_ref · exp(r/β). Её можно посчитать по всему словарю без обучения и использовать как эталон: где окажется идеальный оптимизатор при данной награде и β.

4.2. Поиск на валидации

Сначала 34 прогона на подвыборке 200 тыс. пользователей: GRPO с R1 по сетке β от 0 до 10, остальные награды, все методы, абляции R6 и второй seed для двух конфигураций. Выбор - только по валидации.

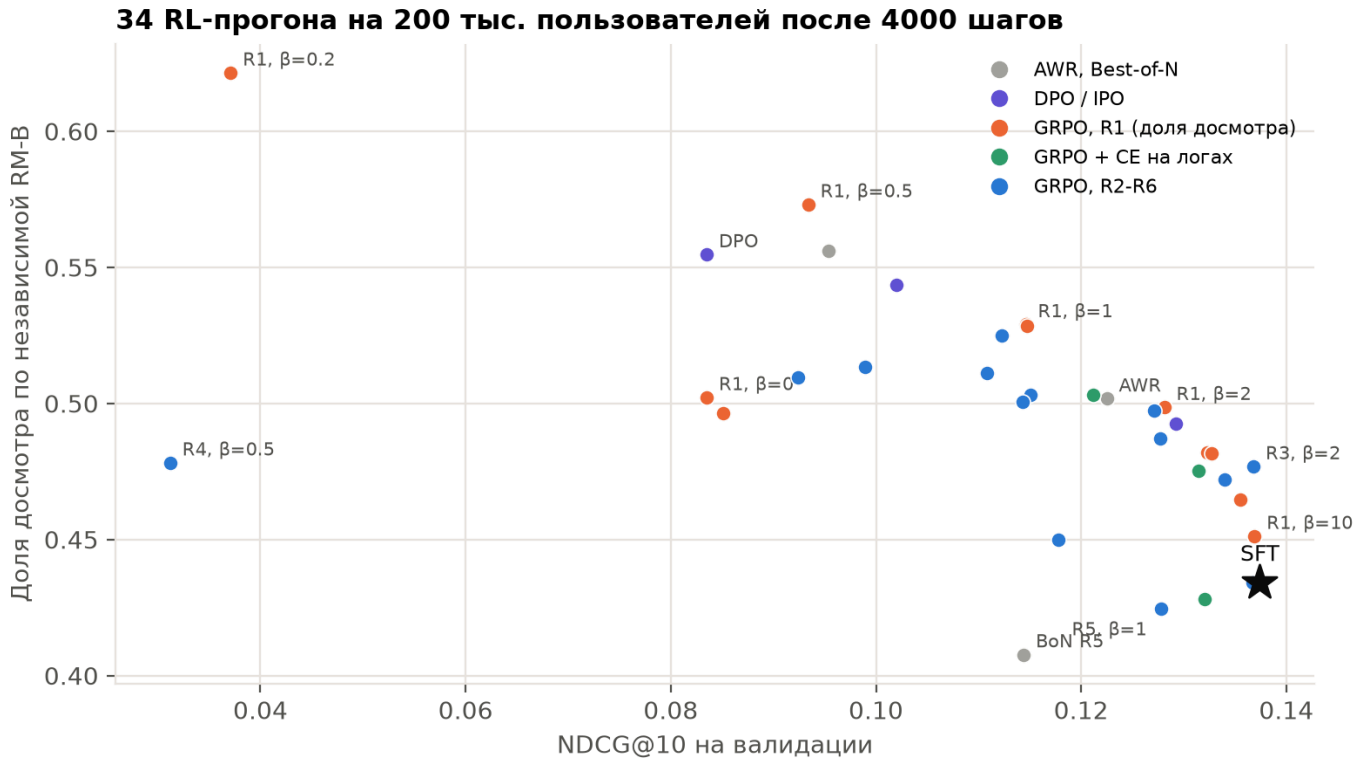


Рисунок 2. NDCG@10 и доля досмотра по независимой RM-B на валидации после 4 000 шагов. Звезда - SFT.

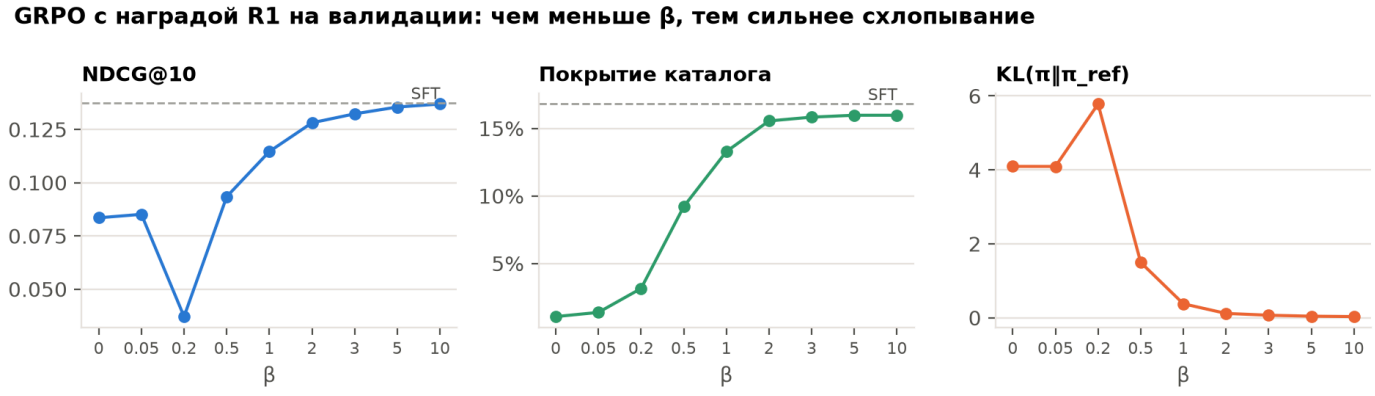


Рисунок 3. GRPO с наградой R1: релевантность, покрытие и KL в конце обучения в зависимости от β.

- **Награда растёт у всех методов.** RM-A на валидации растёт с 0.48 до 0.55–0.70, независимая RM-B - с 0.43 до 0.50–0.62. В среднем 70–80% прироста RM-A подтверждает RM-B.
- **Цена награды - релевантность.** Чем выше награда, тем ниже NDCG: точки всех методов ложатся на одну убывающую кривую (рисунок 2).
- **При β ≤ 0.2 политика схлопывается.** KL растёт до 4–6, покрытие падает до 1–3%, 80% показов уходит на 10 объектов, NDCG падает до 0.04–0.09. Второй seed совпадает до третьего знака, так что это

нестабильность самой задачи, а не шум.

- **R4 (возврат) ломает модель сразу:** при β = 0.5 NDCG падает до 0.03. **R5 не растёт ни у одного метода:** после вычитания среднего досмотра объекта оптимизировать нечего.
- В финал на всех 850 тыс. пользователей отобраны 23 прогона (включая перезапуски после исправлений в RL): R1 и устойчивые к хакингу награды R3, R6–R9 при β от 0.5 до 2, IPO, AWR по доле и по длительности.

4.3. Итоговое сравнение на тесте

Таблица 1. Тест отбора: 10 тыс. пользователей, неделя 16–22.08.2021, ключевые модели. Для SFT - абсолютные значения, для остальных - разница с SFT; proxy - длительность совпавших рекомендаций в % от SFT. **Жирным** - 95% CI парного bootstrap не включает ноль (для трёх seed - на всех трёх; «2/3» - на двух). Это номинальная значимость: тест использовался многократно, интервалы не учитывают адаптивный выбор; проверка финальных кандидатов на свежих пользователях - в разделе 4.4. Полные таблицы с интервалами и всеми вариантами - в приложении.

Модель	NDCG@10	Proxy@10	NDCG@50	Recall@50	Proxy@50	Покрытие	Длит., ч
SFT (абс.)	0.1358	0.751 ч	0.1772	0.3492	1.260 ч	28%	5.4
Popular	**-0.0053**	**-16.5%**	**-0.0168**	**-0.0353**	**-21.5%**	0.3%	4.9
GRPO R1, β=2	**-0.0090**	**-5.6%**	**-0.0100**	**-0.0120**	**-3.5%**	27%	3.7
IPO	**-0.0075**	**-5.5%**	**-0.0073**	**-0.0071**	**-2.5%**	27%	3.8
AWR по доле	**-0.0136**	**-10.7%**	**-0.0139**	**-0.0175**	**-5.3%**	28%	3.4
GRPO R3, β=2	**-0.0017**	-0.1%	**-0.0026**	**-0.0051**	+0.4%	26%	4.6
GRPO R9, β=2	-0.0004	+0.9%	-0.0001	+0.0008	**+1.0%**	25%	4.8
AWR по длительности (3 seed)	+0.0008… +0.0010	**+1.1%… +1.5%**	**+0.0014…+0.0015**	+0.0014… +0.0026	**+2.4%… +2.7%**	27%	5.7–5.8
CRR γ=0 (3 seed)	-0.0020…-0.0009	**+3.0%… +3.7%**	-0.0025…-0.0017 (2/3)	**-0.0066…-0.0050**	**+5.1%… +5.3%**	23–24%	7.4–7.5
CRR γ=0.9 (3 seed)	**-0.0200…-0.0196**	**-9.8%…-8.6%**	**-0.0217…-0.0211**	**-0.0310…-0.0297**	**-3.2%…-2.7%**	30%	5.2–5.3

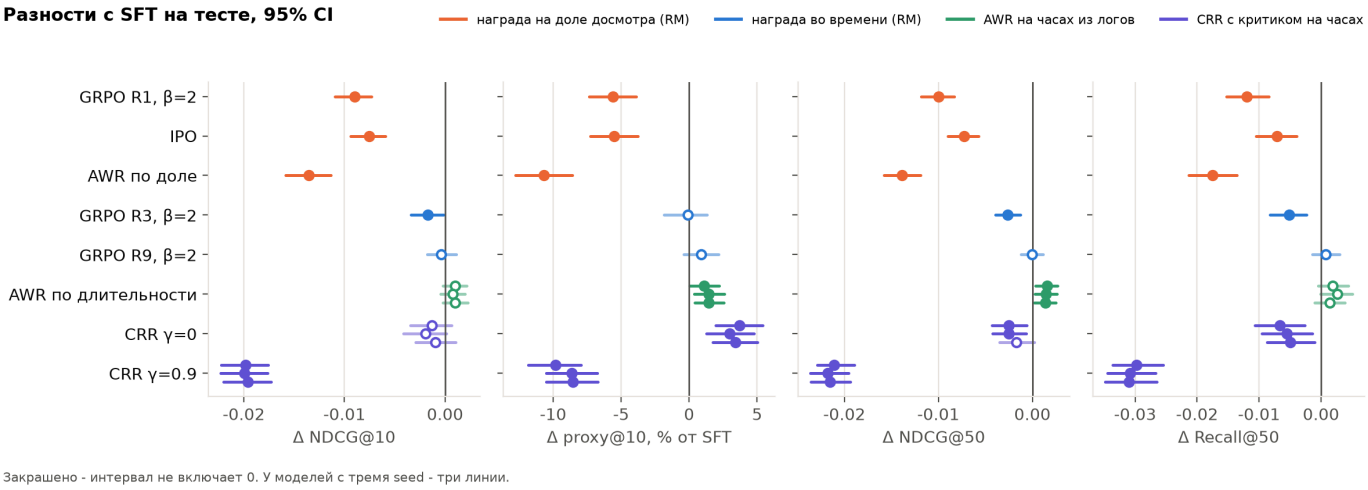


Рисунок 4. Разности с SFT для моделей из таблицы 1: NDCG@10, proxy@10 (в % от SFT), NDCG@50 и Recall@50. У AWR по длительности и CRR - по линии на каждый из трёх seed; закрашенная точка - интервал не включает ноль.

- **Награды на доле досмотра** (R1, IPO, AWR по доле; так же R6 в таблице A1) значимо теряют и релевантность (NDCG@10 на 5–10%), и proxy (на 5–11%), хотя обе reward model обещают рост.

- **Награды на времени просмотра** (R3, R9; так же R7α и R8) остаются рядом с SFT: у R3 падение NDCG значимо, но не больше 1.3% на @10; у R9 значимого отличия по релевантности нет, а proxy@50 значимо растёт на 1%.
- **AWR по длительности из логов** - единственная модель, которая на всех трёх seed значимо улучшает proxy (+1.1–1.5% на @10, +2.4–2.7% на @50) и NDCG@50, без значимой потери NDCG@10. На первом seed нижняя граница CI proxy@10 близка к нулю (+0.0004 ч). Результат устойчив к трём seed RL-стадии на этом тесте; независимо он подтверждён на свежих пользователях (раздел 4.4).
- **CRR γ = 0** даёт самый большой proxy, но значимо теряет Recall@50 и сдвигает рекомендации в длинное (разделы 4.4 и 4.5).

4.4. Подтверждение на свежих пользователях

Тест из таблицы 1 (10 тыс. пользователей) использовался многократно при выборе методов, наград, β, RM и глубины списка, поэтому его интервалы не учитывают адаптивный выбор: различия на нём номинально значимы, а три seed показывают только устойчивость RL-стадии на тех же данных. Для проверки мы заранее объявили финальных кандидатов - AWR по длительности, CRR γ = 0 и GRPO R9, β=2 (во всех случаях seed 1) - и один раз оценили их (`eval_fresh.py`) на всех остальных пользователях тестовой недели: **81 405 человек, которых не было ни в тестовой, ни в валидационной выборке**. Их целевая неделя ни разу не использовалась; история до 09.08 участвовала в обучении, как и у всех. Протокол и метрики те же.

Таблица 2. Свежие пользователи тестовой недели, единственная оценка. Для SFT - абсолютные значения, для остальных - разница с SFT и 95% CI парного bootstrap; **жирным** - CI не включает ноль.

Модель	NDCG@10	Proxy@10	NDCG@50	Recall@50	Proxy@50	Длит., ч
SFT (абс.)	0.1362	0.736 ч	0.1777	0.3523	1.262 ч	5.4
Popular	**-0.0048**	**-14.4%**	**-0.0147**	**-0.0290**	**-20.8%**	4.9
AWR по длительности	**+0.0010 [+0.0006; +0.0013]**	**+2.6% [+2.2; +3.0]**	**+0.0012 [+0.0008; +0.0015]**	+0.0008 [+0.0000; +0.0015]	**+2.3% [+2.0; +2.5]**	5.7
CRR γ=0	**-0.0016 [-0.0024; -0.0008]**	**+5.7% [+5.0; +6.3]**	**-0.0020 [-0.0027; -0.0013]**	**-0.0044 [-0.0057; -0.0033]**	**+4.5% [+4.1; +5.0]**	7.4
GRPO R9, β=2	-0.0000 [-0.0005; +0.0004]	**+0.9% [+0.4; +1.4]**	+0.0002 [-0.0003; +0.0006]	-0.0006 [-0.0013; +0.0002]	**+1.1% [+0.9; +1.4]**	4.8

- **AWR по длительности подтверждается:** на свежих пользователях он значимо улучшает и proxy (+2.6% на @10), и NDCG@10 и @50; Recall@50 растёт на границе значимости.
- **CRR γ = 0 подтверждается как компромисс, а не выигрыш:** proxy растёт сильнее всех (+5.7%), но NDCG@10, NDCG@50 и Recall@50 значимо падают, а рекомендации уходят в длинный контент (7.4 ч). На тесте отбора падение NDCG@10 было незначимым - на большой выборке оно видно.
- **GRPO R9 даёт небольшой, но подтверждённый прирост proxy** (+0.9–1.1%) без значимого изменения релевантности.
- Это проверка на нетронутых пользователях той же недели, а не на другом периоде: сдвиг во времени она не проверяет.

4.5. Офлайн RL с критиком на логах: CRR и AWR на наблюдаемой награде

Все методы выше, кроме AWR, оптимизируют оценку reward model. Здесь политика учится только на реальных следующих объектах из логов, а вес примера задаёт наблюдаемая награда или критик, обученный на ней. Протокол тот же: 850 тыс. пользователей, старт с SFT, 4 000 шагов, батч 256, lr 3e-5, без dropout, тот же тест и bootstrap.

- **Критик Q(s, a):** тело GPT-2 из SFT и линейная голова на весь словарь, Q(s, a) = w_a · h(s) + b_a, регрессия на Монте-Карло-возврат G_t = Σ γ^k r_{t+k} с наградой «часы просмотра (не больше 3)» или «досмотр > 50%». Вместо TD с target-сетью из исходной работы используем MC: на фиксированных

логах оба оценивают Q логирующей политики. Возврат считается **до границы train (09.08.2021)** и потому цензурирован: у событий ближе к границе будущее короче (просмотры по 1 ч в дни 1, 2, 10 при границе на 9-м дне и γ = 0.9 дают цели 1.9, 1 и 0; события валидации брать нельзя - утечка). Дисконт - по просмотрам, а не по дням. При γ = 0 цензурирования нет.

- **CRR:** A = Q(s, a) − Σ π(a'|s) Q(s, a') по всему словарю, вес exp(Â/β) с ограничением 20 или бинарный 1[A > 0], где Â = A / std(A) по батчу; веса делятся на среднее по батчу, как в AWR.
- **AWR с выученным baseline:** тот же вес с A = G_t − V(s), V(s) = Σ π(a|s) Q(s, a). **AWR на бинарной награде:** вес exp((r − r̄)/0.5), r - «досмотр > 50%» или «≥ 90%».

Результаты (таблица 1 и полная таблица A2):

- **CRR с наградой одного шага (γ = 0)** даёт +3.0–3.7% proxy@10 на трёх seed, все интервалы выше нуля, NDCG@10 на тесте отбора значимо не меняется (на свежих пользователях падение значимо, раздел 4.4). Цена - сдвиг в длинный контент (7.4 ч, сериалы 43%), покрытие 23–24% и значимое падение Recall@50. Proxy суммирует часы и сам поощряет длинные объекты, так что выигрыш в основном идёт от сдвига в длинное, а не от лучшего угадывания.
- **Многошаговый возврат в проверенной реализации вредит.** При γ = 0.9 CRR теряет 9–10% proxy и 15% NDCG на трёх seed; ни β, ни бинарный вес, ни втрое больше шагов не помогают, γ = 0.5 - промежуточный случай. Критик на G_t предсказывает возврат лучше среднего по объекту (Spearman 0.49 против 0.25). Возможное объяснение: он в основном улавливает активность пользователя, а не сигнал для выбора объекта (похоже на возврат R4, раздел 5.5); напрямую мы это не проверяли. Кроме того, провал не отделён от цензурирования возврата на границе train, поэтому вывод относится к этой реализации, а не к многошаговой награде вообще.
- **Бинарные награды на досмотре повторяют хакинг доли:** AWR и CRR на «досмотр > 50%» и «полный досмотр» уводят в короткое (3.3–3.9 ч) и теряют 6–20% proxy. **AWR с V(s)** при γ = 0.9 теряет мягче (−2% proxy, −6% NDCG).

4.6. Персональная reward model (RM-P) и калибровка

RM-A видит только объекты истории, но не то, сколько из каждого пользователь досмотрел. RM-P (`rm_personal.py`) добавляет к ней 8 признаков пользователя на момент контекста - средний досмотр, средние часы, среднюю длительность просмотренного, долю сериалов, досмотр отдельно на сериалах и на фильмах, долю полных досмотров, число просмотров - и их произведения с длительностью, типом и средним досмотром объекта-кандидата. Головы и обучение те же, что у RM-A с головой склонности на окне 7 дней, поэтому RM-P заменяет RM-A в R1, R3, R5 и R9. Качество проверяется на тестовой неделе, калибровка - изотонической регрессией, обученной на валидационной неделе.

Таблица 3. Доля досмотра на тестовой неделе (выборка отбора). «Внутри пользователя»: и истинная доля, и предсказание центрируются по среднему каждого пользователя, затем считается один общий Spearman по всем строкам; пользователи с ≥ 3 строками - 3 007 пользователей, 16 670 строк (`within_user_ci.py`). Разница RM-P − RM-A внутри пользователя +0.013, 95% CI бутстрапа по пользователям [+0.008; +0.019].

	Средний досмотр объекта	RM-A	RM-P
Spearman	0.340	0.385	0.478
Spearman внутри пользователя	0.307	0.335	0.348
ECE до / после изотонической калибровки	-	0.029 / 0.011	0.033 / 0.010

Таблица 4. GRPO с наградой на RM-A и на RM-P, тест отбора. Обозначения как в таблице 1.

Награда	RM	NDCG@10	Proxy@10	NDCG@50	Proxy@50	Покрытие	Длит., ч
R1, β=2	RM-A	**-0.0090**	**-5.6%**	**-0.0100**	**-3.5%**	27%	3.7
R1, β=2	RM-P	**-0.0071**	**-4.6%**	**-0.0080**	**-2.7%**	27%	3.9
R3, β=2	RM-A	**-0.0017**	-0.1%	**-0.0026**	+0.4%	26%	4.6
R3, β=2	RM-P	**-0.0016**	-0.2%	**-0.0023**	+0.3%	26%	4.6
R5, β=1	RM-A	**-0.0109**	**-7.0%**	**-0.0099**	**-2.8%**	26%	6.0
R5, β=1	RM-P	**-0.0052**	**-3.7%**	**-0.0042**	-0.8%	27%	5.7
R9, β=2	RM-A	-0.0004	+0.9%	-0.0001	**+1.0%**	25%	4.8
R9, β=2	RM-P	-0.0004	+0.4%	-0.0000	**+0.9%**	26%	4.8

- **RM-P заметно лучше предсказывает досмотр** (Spearman 0.478 против 0.385; на валидационной неделе 0.484 - как независимая RM-B, 0.479). Внутри одного пользователя её преимущество небольшое, хотя и значимое: 0.348 против 0.335 у RM-A (+0.013 [+0.008; +0.019]) и 0.307 у среднего досмотра объекта. Значит, большая часть роста общего Spearman связана с различиями между пользователями (кто-то досматривает всё, кто-то бросает); это сравнение корреляций, а не разложение сигнала.
- **Что это значит для наград.** В аддитивных наградах R1 и R5 сдвиг, общий для всех объектов одного пользователя, не меняет выбор: в GRPO он вычитается внутри группы. В мультипликативных R3 и R9 тот же сдвиг входит как b(s) · h(a) и меняет выбор в пользу длинных объектов, так что там уровень пользователя в принципе может влиять на политику.
- **В RL:** на наградах в часах (R3, R9) RM-P даёт те же результаты, что RM-A. На доле досмотра (R1) и на остатке R5 вред заметно меньше (у R5 падение NDCG вдвое меньше, proxy@50 перестаёт значимо падать), но значимого выигрыша нет ни у одной модели.
- **Калибровка.** Изотоническая калибровка на валидации снижает ECE доли досмотра с 0.03 до 0.01 у обеих моделей. Это монотонное преобразование: порядок объектов для R1 не меняется, и мы не обучали RL на откалиброванной награде. Вероятность клика откалибровать нельзя: в KION нет показов.

5. Разобрали, что получилось

5.1. Как меняется поведение: хакинг через короткий контент

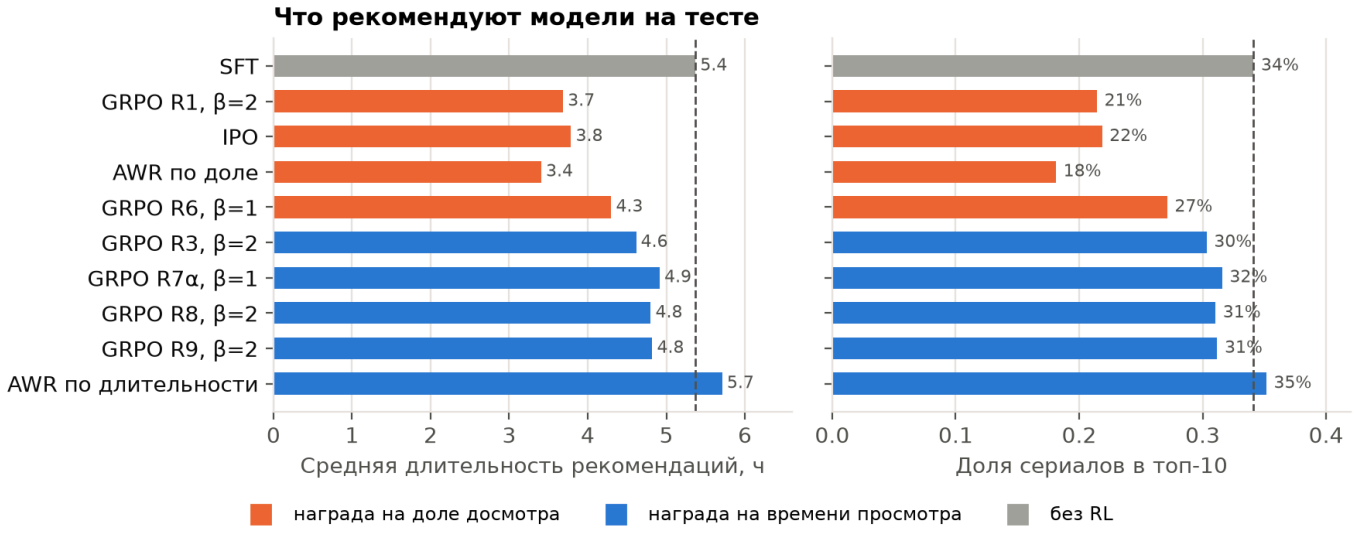


Рисунок 5. Средняя длительность рекомендаций и доля сериалов в топ-10 на тесте. Пунктир - SFT.

Награда растёт в основном за счёт выбора объекта, а не персонализации. Короткие фильмы досматривают чаще, и обе reward model это знают. Поэтому на доле досмотра RL уводит рекомендации в

короткое: средняя длительность падает с 5.4 до 3.4–3.8 ч, доля сериалов - с 34% до 18–22% (на валидации при малом β - до 2 ч и 4%). Это ровно сценарий из условия задания. RM-B подтверждает «прирост» досмотра, потому что разделяет то же смещение, а proxy длительности из логов падает на 5–11%. Награды в часах этот перекос в основном снимают: длительность 4.6–4.9 ч, сериалы 30–32%; AWR по длительности даже сдвигает рекомендации в длинное (5.7 ч).

Персонального выигрыша мы не нашли. Награда R5, из которой вычтен средний досмотр объекта, не растёт ни у одного метода. Это наблюдение, а не доказательство: остаток содержит и ошибки калибровки RM на уровне объекта, так что R5 не изолирует персональную часть строго. С признаками пользователя (RM-P, раздел 4.6) общий Spearman растёт сильно, а внутри пользователя - на 0.013 [+0.008; +0.019].

Схлопывание при малом β (рисунок 3) - вторая форма хакинга: политика находит несколько объектов с высокой предсказанной наградой и рекомендует их всем. При этом RM-A на валидации у таких прогонов ниже, чем при β = 0.5: политика переобучается на контексты обучения.

5.2. Насколько оптимизатор близок к оптимуму

Чтобы понять, ограничивает ли результат алгоритм или награда, мы сравнили обученные политики с точным оптимумом π*_β. Для каждой награды строится фронт «наибольшее E_π[r] при данном KL(π‖π_ref)» по 41 значению β, а у обученных стохастических политик E[r] и KL считаются по всему словарю на 5 тыс. тестовых контекстов. Сравнение при равном KL не зависит от масштаба награды и нормировки advantage.

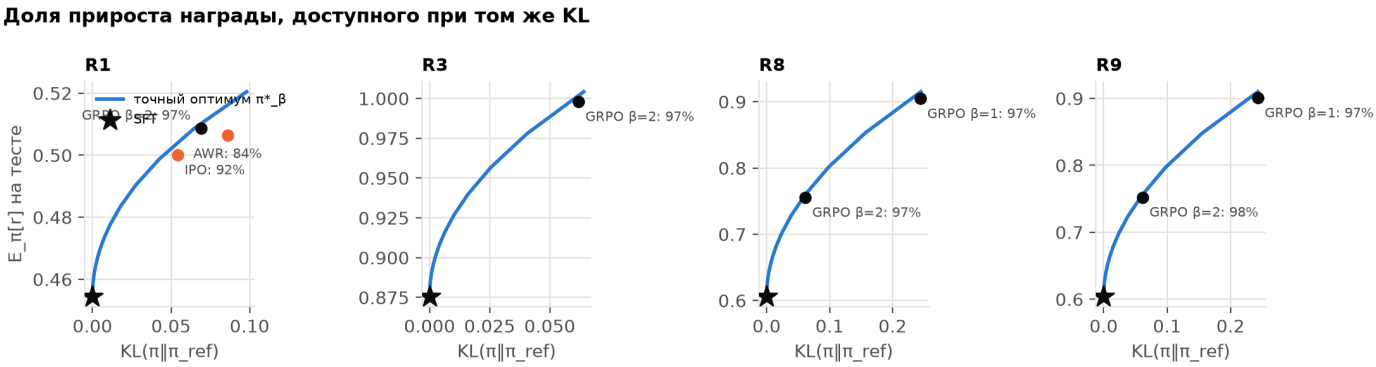


Рисунок 6. Фронт точного оптимума и обученные политики; подписи - доля прироста E[r] над SFT, доступного при том же KL.

GRPO берёт 97–98% доступного прироста для R1, R3, R8 и R9 при обоих β. IPO берёт 92%, AWR по доле - 84%, но у них другая функция потерь. Значит, запаса в оптимизации почти нет: всё, что можно получить с данной наградой при данном KL, GRPO получает. Улучшать нужно награду. Методы на логах из раздела 4.5 оптимизируют не RM, поэтому их доля на фронте ближайшей награды - сравнение сбоку: CRR γ = 0 берёт 73–74% прироста R3, AWR по длительности 55–59%, CRR γ = 0.9 около 36%.

5.3. Сохраняется ли релевантность: компромисс задаёт награда

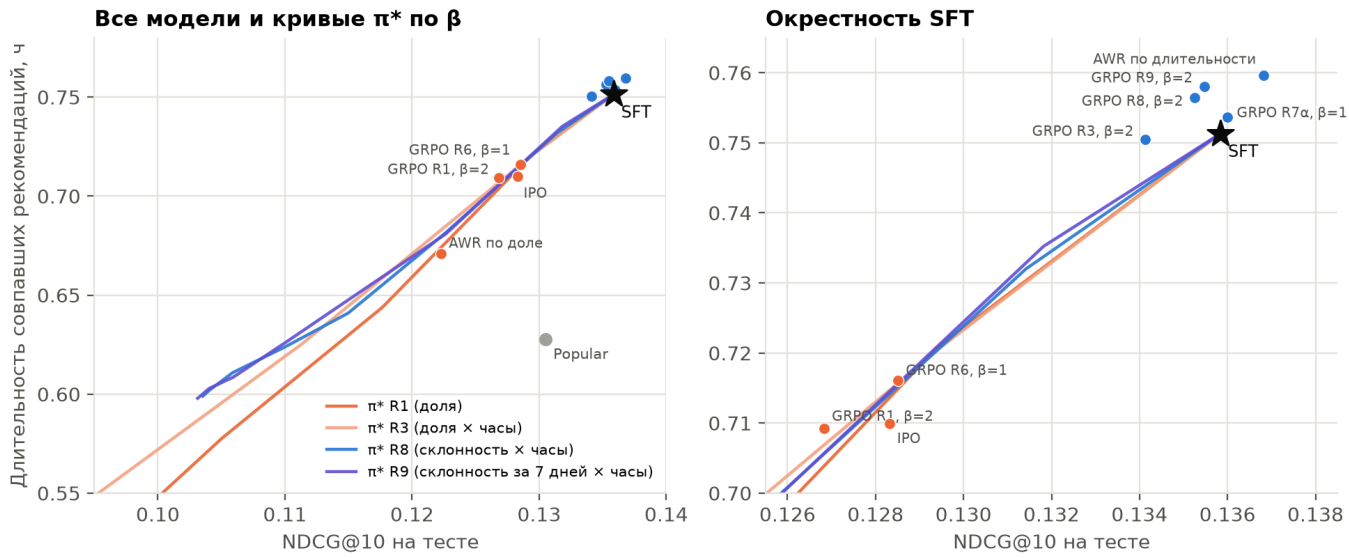


Рисунок 7. NDCG@10 и длительность совпавших рекомендаций на тесте. Линии - топ-10 аналитического оптимума π для разных наград по сетке β от 0.005 до 0.5, точки - обученные модели.*

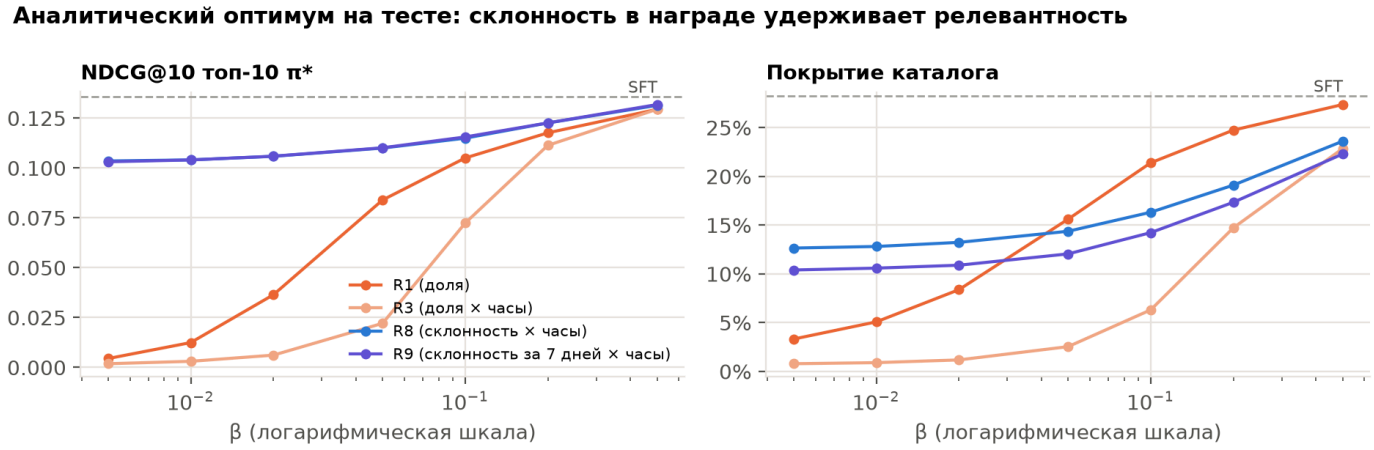


Рисунок 8. Релевантность и покрытие топ-10 оптимума π в зависимости от β.*

- **Модели на reward model лежат на кривых оптимума.** GRPO с разными β, IPO, AWR по доле, Best-of-N и GRPO + CE - сдвиги вдоль одной кривой, а топ-10 π* с той же наградой даёт близкие точки. Алгоритм определяет, *где* на кривой окажется модель, а *форму* кривой задаёт награда.
- **Концентрации «всем одно и то же» при β ≥ 1 нет:** покрытие 22–28% против 28% у SFT, доля 10 самых частых объектов 0.41–0.45 против 0.42 (у популярности покрытие 0.3%). Схлопывание появляется только при β < 0.5 или у R8 при β = 0.5 (покрытие 16%).
- **Score склонности в награде меняет форму кривой.** При уменьшении β до 0.005 оптимум R1 и R3 теряет релевантность почти полностью (NDCG@10 0.002–0.005), а оптимум R8 и R9 держит NDCG@10 ≥ 0.10. Покрытие у R8 и R9 при этом всё равно падает до 10–13% против 28% у SFT, так что снимать KL-штраф нельзя и с ними; β = 0 мы не проверяли.

Что не помогло: R2 ведёт себя как R1 с большим β; R6 почти не отличается от R1 - три RM-A, обученные от одной SFT, почти не расходятся, а штраф за популярность режет релевантность; R7 без сглаживания превращается в «повтори SFT», потому что π_ref слишком острая; R8log совпадает с R8; GRPO + CE и Best-of-N дают те же точки на кривой.

5.4. Генерация на 5 шагов вперёд

Жадно генерируем 5 объектов, каждый раз добавляя предыдущий в контекст как «просмотренный», на 2 тыс. тестовых пользователей. На каждом шаге сравниваем оценку RM-A того же объекта на сгенерированном контексте и на реальной истории. Контроль для попаданий - объект того же ранга из топ-5 по неизменной реальной истории.

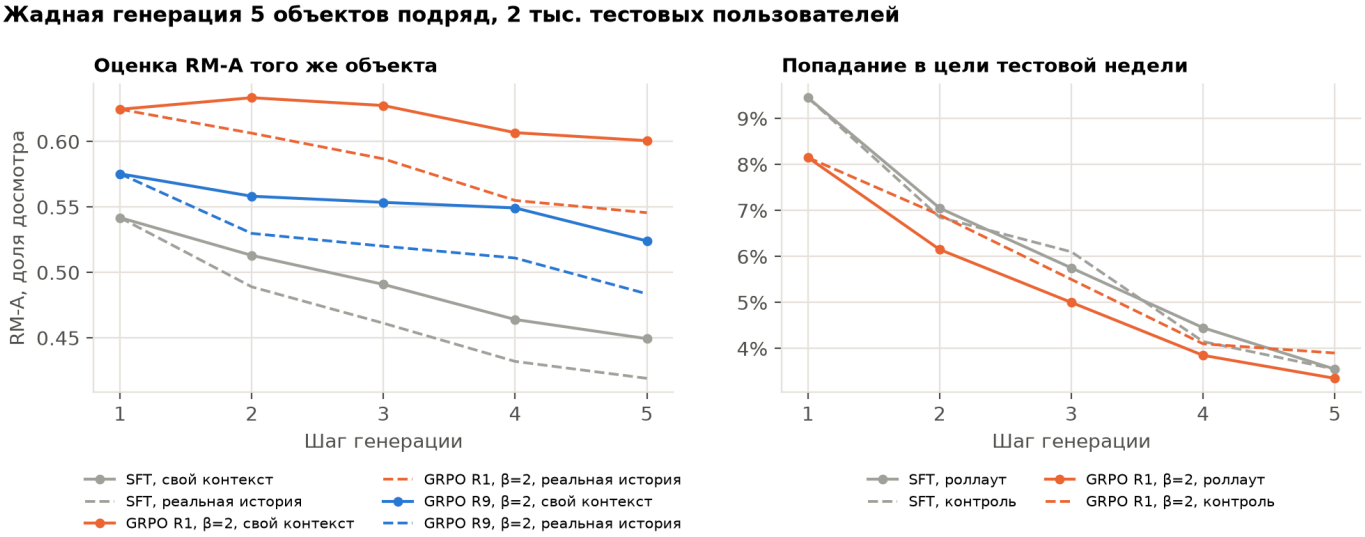


Рисунок 9. Слева - RM-A на собственном контексте модели и на реальной истории, справа - доля попаданий в цели тестовой недели у роллаута и у контроля.

Шаг	RM-A своя / реальная, SFT	RM-A своя / реальная, GRPO R1	RM-A своя / реальная, GRPO R9	Попадание роллаут / контроль, SFT	Попадание роллаут / контроль, GRPO R1
1	0.542 / 0.542	0.625 / 0.625	0.575 / 0.575	9.5% / 9.5%	8.2% / 8.2%
2	0.513 / 0.489	0.633 / 0.606	0.558 / 0.530	7.0% / 6.9%	6.1% / 6.9%
3	0.491 / 0.461	0.627 / 0.587	0.554 / 0.520	5.8% / 6.1%	5.0% / 5.5%
5	0.449 / 0.419	0.601 / 0.546	0.524 / 0.484	3.5% / 3.5%	3.4% / 3.9%

- **Оценка RM смещается вверх.** На собственном контексте RM-A систематически выше, чем на реальной истории, и разрыв растёт с шагом: у R1 к 5-му шагу 0.055. Модель «подтверждает» свои же рекомендации: контекст из коротких фильмов делает следующий короткий фильм ещё более «досматриваемым». RM-A на реальной истории тоже не истинный отклик, поэтому это сдвиг оценки, а не доказанное завышение, но награда, посчитанная на собственных роллаутах, оптимистичнее, чем на реальном контексте.
- **Дрейф по попаданиям небольшой.** У SFT роллаут и контроль почти совпадают, так что падение по шагам - обычное падение качества по рангу. У R1 на шагах 2–5 роллаут ниже контроля на 0.25–0.75 п.п., что может указывать на небольшой дрейф; статистическая неопределённость этих разниц отдельно не оценивалась.

5.5. Можно ли приблизиться к долгосрочным целям

- **Возврат в сервис (R4)** - самая прямая награда за долгосрочную цель: вероятность, что пользователь посмотрит что-то ещё в следующие 7 дней. Голова слабая (ROC-AUC 0.684), и GRPO ломает её сразу. Возможное объяснение: в KION возврат слабо связан с тем, какой объект рекомендован, и сигнал тонет в общей активности пользователя.
- **Время просмотра вместо доли** (R3, R7–R9) - ближайший к долгосрочной ценности сигнал, который есть в данных. Эти награды не уводят в короткое и держат релевантность, но офлайн не показывают значимого выигрыша.

- **Что проверяется офлайн.** Proxy длительности считается только по объектам, которые пользователь выбрал сам при старой системе, и по всей длительности агрегата. Он вознаграждает «угадать, что пользователь и так посмотрит» и не видит выигрыша от рекомендации того, что пользователь без нас не нашёл бы. Логов показов и вероятностей показа в KION нет, поэтому корректная off-policy оценка невозможна. Офлайн видно ухудшение (награды на доле теряют 5–11% proxy), но интервал, включающий ноль, не доказывает отсутствие вреда, а падение proxy само по себе не доказывает причинное снижение просмотра.
- **Что требует онлайна.** Сам выигрыш в удержании и времени просмотра проверяется только A/B-тестом с метриками возврата и времени за 2–4 недели.

5.6. Вычислительные затраты

На ноутбуке с RTX 4060 Laptop обучение SFT на 850 тыс. пользователей заняло около 40 минут, каждая reward model - около 5 минут, один RL-прогон на 4 000 шагов - 3–5 минут, эпоха критика для CRR - около 2.5 минуты. Аналитический оптимум считается без обучения за секунды на всю сетку β.

6. Сделали выводы

1. **RL максимизирует заданную награду, но так, как предсказывало условие.** Награда «доля досмотра» уводит рекомендации в короткий контент и при малом β схлопывает их на несколько объектов. Обе reward model подтверждают «прирост», потому что разделяют одно смещение на уровне объекта, а релевантность и длительность совпавших рекомендаций значимо падают.
2. **Узкое место - награда, а не оптимизатор.** GRPO с точным KL берёт 97–98% прироста, доступного при том же KL, и все конфигурации на reward model ложатся на кривые аналитического оптимума (методы на логах из раздела 4.5 оптимизируют другую цель и сюда не входят). Улучшать имеет смысл форму награды и reward model, а не алгоритм.
3. **Награда во времени просмотра сохраняет релевантность.** Переход от доли к часам и добавление score склонности меняют саму кривую компромисса: NDCG теряет не больше 1.3% (у R7α, R8 и R9 значимого отличия от SFT нет), ухода в короткое нет, а при уменьшении β релевантность падает намного медленнее. Покрытие при этом всё равно снижается, так что KL-штраф нужен.
4. **Лучший офлайн-результат даёт RL на наблюдаемых часах из логов.** На свежих пользователях, оценённых один раз, AWR, взвешенный длительностью, значимо улучшает и proxy длительности (+2.6%), и NDCG; CRR с критиком на часах одного шага поднимает proxy сильнее (+5.7%), но ценой релевантности и сдвига в длинный контент; из моделей на reward model небольшой прирост proxy (+0.9%) без потери релевантности даёт GRPO R9. Все различия на тесте отбора номинальны, независимая проверка - только эта, и она в той же неделе. Многошаговый возврат в проверенной реализации не помог; возможные причины - критик в основном улавливает активность пользователя, а не сигнал для выбора объекта, и возврат цензурирован на границе train, так что свойства самой многошаговой награды от этого не отделены.
5. **Персональный сигнал для выбора объекта слабый.** RM-A почти целиком объясняется свойствами объекта, и награда без них (R5) не оптимизируется. Признаки пользователя (RM-P) заметно улучшают предсказание досмотра (Spearman 0.385 → 0.478), а различение объектов внутри пользователя - немного, но значимо (0.335 → 0.348, +0.013 [+0.008; +0.019]). RL с RM-P значимого выигрыша не даёт, только меньше вредит на доле досмотра.
6. **Многошаговая генерация завышает оценку награды.** На собственных роллаутах RM-A оптимистичнее, чем на реальной истории, и разрыв растёт с шагом, поэтому награду для многошагового RL нельзя считать по сгенерированному контексту без поправки.

Ограничения.

1. **Только офлайн-данные:** контекстные бандиты, онлайн-исследование и on-policy RL на реальных откликах недоступны, поэтому RL оптимизирует оценку reward model, а не реакцию пользователей.

2. **Агрегированный KION:** одна строка на пару user–item, повторов нет, порядок внутри дня неизвестен, `watched_pct` у сериалов суммарный. Длительность объекта оценена, а не дана.
3. **Обе reward model и proxy видят только просмотренное.** Нет вероятности показа и клика, поэтому корректная off-policy оценка невозможна; proxy берёт всю длительность агрегата, а не недельную.
4. **Score склонности не откалиброван** (позитив против случайных объектов), поэтому R8 и R9 - эвристика, а не ожидаемое время в строгом смысле.
5. **RM-B смещена так же, как RM-A,** и не страхует от хакинга на уровне объекта: при малом β с R3 она обещает удвоение часов.
6. **Разброс по seed оценён только для RL:** два seed совпадают до третьего знака; SFT и reward model с другими seed не переобучались.
7. **Тест отбора использовался многократно,** поэтому его интервалы номинальны, а три seed показывают только устойчивость RL-стадии. Финальные кандидаты один раз проверены на 81 тыс. нетронутых пользователей той же недели; другой период мы не проверяли, а proxy сам поощряет длинный контент, что важно для CRR.
8. **Многошаговый возврат для критика цензурирован** на границе train: просмотры после 09.08.2021 в него не входят, и у поздних событий горизонт короче. Провал CRR и AWR с V(s) при $\gamma > 0$ не отделён от этого эффекта; корректная проверка требует учёта цензурирования (например, нормировки на доступный горизонт или обучения только на событиях с полным горизонтом).

Что дальше. Следующие шаги требуют данных и доступа, которых в задании нет.

1. A/B-тест на возврат и время просмотра за 2–4 недели - единственная честная проверка долгосрочного эффекта.
2. Логи показов и вероятностей показа: с ними возможны корректная off-policy оценка, вероятность клика как награда и проверка выигрыша на объектах, которые пользователь без рекомендаций не нашёл бы.
3. Онлайн-обратная связь на собственные рекомендации модели: контекстные бандиты и исследование вместо обучения только на исторических контекстах.

Приложение. Полные таблицы

Все таблицы - тест, те же 10 тыс. пользователей; Δ - разница с SFT, в скобках 95% CI парного bootstrap.

Таблица A1. Тест, 10 тыс. пользователей, неделя 16–22.08.2021. Δ - разница с SFT, в скобках 95% CI парного bootstrap.

Модель	NDCG@10 (Δ)	Длительность совпавших, ч (Δ)	RM-A, доля	RM-B, ч	Покрытие	Длит., ч	Сериалы
Popular	0.1305 (-0.0053 [-0.0093; -0.0013])	0.628 (-0.124 [-0.148; -0.100])	0.398	0.80	0.3%	4.9	47%
SFT	**0.1358**	**0.751**	0.480	0.87	28%	5.4	34%
GRPO R1, β=2	0.1268 (-0.0090 [-0.0110; -0.0073])	0.709 (-0.042 [-0.055; -0.029])	0.551	0.93	27%	3.7	21%
IPO	0.1283 (-0.0075 [-0.0094; -0.0059])	0.710 (-0.041 [-0.055; -0.028])	0.543	0.93	27%	3.8	22%
AWR по доле	0.1223 (-0.0136 [-0.0158; -0.0113])	0.671 (-0.080 [-0.096; -0.064])	0.556	0.94	28%	3.4	18%
GRPO R6, β=1	0.1285 (-0.0073 [-0.0090; -0.0053])	0.716 (-0.035 [-0.049; -0.022])	0.536	0.98	25%	4.3	27%
GRPO R3, β=2	0.1341 (-0.0017 [-0.0034; -0.0002])	0.750 (-0.001 [-0.014; +0.010])	0.522	0.96	26%	4.6	30%
GRPO R7α, β=1	0.1360 (+0.0002 [-0.0012; +0.0014])	0.754 (+0.002 [-0.006; +0.010])	0.504	0.92	27%	4.9	32%
GRPO R8, β=2	0.1353 (-0.0006 [-0.0020; +0.0009])	0.756 (+0.005 [-0.005; +0.014])	0.510	0.93	26%	4.8	31%
GRPO R9, β=2	0.1355 (-0.0004 [-0.0018; +0.0011])	0.758 (+0.007 [-0.003; +0.016])	0.510	0.93	25%	4.8	31%
AWR по длительности	**0.1368 (+0.0010 [-0.0002; +0.0022])**	**0.760 (+0.0083 [+0.0004; +0.0166])**	0.489	0.90	27%	5.7	35%

Таблица A2. Тест, те же 10 тыс. пользователей. Δ - разница с SFT, в скобках 95% CI парного bootstrap. Последний столбец - доля прироста E[r] над SFT, доступного при том же KL (раздел 5.2), для ближайшей награды на RM: часы → R3, доля → R1.

Модель	NDCG@10 (Δ)	Длительность совпавших, ч (Δ)	Покрытие	Длит., ч	Сериалы	Доля оптимума
SFT	**0.1358**	**0.751**	28%	5.4	34%	-
AWR по длительности, seed 1	0.1368 (+0.0010 [-0.0002; +0.0022])	0.760 (+0.0083 [+0.0004; +0.0166])	27%	5.7	35%	59% (R3)
AWR по длительности, seed 2	0.1366 (+0.0008 [-0.0004; +0.0020])	0.762 (+0.0109 [+0.0029; +0.0194])	27%	5.7	35%	57% (R3)
AWR по длительности, seed 3	0.1369 (+0.0010 [-0.0002; +0.0023])	0.762 (+0.0109 [+0.0030; +0.0191])	27%	5.8	36%	55% (R3)
AWR, досмотр > 50%	0.1271 (-0.0087 [-0.0106; -0.0071])	0.702 (-0.049 [-0.062; -0.035])	28%	3.9	22%	81% (R1)
AWR, полный досмотр	0.1247 (-0.0111 [-0.0131; -0.0092])	0.690 (-0.061 [-0.075; -0.046])	28%	3.8	20%	80% (R1)
AWR с V(s), γ=0.9	0.1281 (-0.0077 [-0.0091; -0.0063])	0.734 (-0.017 [-0.027; -0.006])	28%	5.2	32%	29% (R3)
CRR γ=0, seed 1	**0.1345 (-0.0013 [-0.0034; +0.0007])**	**0.779 (+0.028 [+0.015; +0.041])**	24%	7.4	43%	74% (R3)
CRR γ=0, seed 2	0.1339 (-0.0020 [-0.0041; +0.0001])	0.774 (+0.022 [+0.010; +0.036])	23%	7.4	43%	73% (R3)
CRR γ=0, seed 3	0.1349 (-0.0009 [-0.0029; +0.0011])	0.777 (+0.026 [+0.013; +0.038])	23%	7.5	44%	73% (R3)
CRR γ=0.5	0.1313 (-0.0046 [-0.0067; -0.0024])	0.764 (+0.012 [-0.002; +0.025])	24%	7.2	43%	73% (R3)
CRR γ=0.9	0.1160 (-0.0198 [-0.0222; -0.0176])	0.678 (-0.074 [-0.089; -0.060])	30%	5.2	32%	36% (R3)
CRR γ=0.9, β=2	0.1257 (-0.0102 [-0.0118; -0.0084])	0.727 (-0.025 [-0.036; -0.013])	30%	5.2	33%	36% (R3)
CRR γ=0.9, β=0.5	0.1016 (-0.0342 [-0.0372; -0.0311])	0.615 (-0.136 [-0.155; -0.118])	31%	5.4	32%	32% (R3)
CRR γ=0.9, бинарный вес	0.0956 (-0.0403 [-0.0436; -0.0366])	0.595 (-0.156 [-0.176; -0.136])	27%	5.0	30%	40% (R3)
CRR γ=0.9, 12 тыс. шагов	0.1141 (-0.0217 [-0.0242; -0.0194])	0.675 (-0.076 [-0.090; -0.061])	30%	5.2	32%	38% (R3)
CRR на «досмотр > 50%», γ=0.9	0.1036 (-0.0322 [-0.0350; -0.0296])	0.599 (-0.152 [-0.172; -0.134])	33%	3.3	16%	55% (R1)

Таблица A3. Тест, топ-50 (`eval_at50.py`, те же сохранённые модели без переобучения). Δ - разница с SFT, в скобках 95% CI парного bootstrap.

Модель	NDCG@50 (Δ)	Recall@50 (Δ)	Длительность совпавших @50, ч (Δ)
Popular	0.1603 (-0.0168 [-0.0207; -0.0131])	0.3139 (-0.0353 [-0.0420; -0.0283])	0.990 (-0.271 [-0.306; -0.238])
SFT	**0.1772**	**0.3492**	**1.260**
GRPO R1, β=2	0.1672 (-0.0100 [-0.0118; -0.0083])	0.3372 (-0.0120 [-0.0153; -0.0084])	1.216 (-0.044 [-0.057; -0.029])
IPO	0.1699 (-0.0073 [-0.0090; -0.0057])	0.3421 (-0.0071 [-0.0105; -0.0039])	1.229 (-0.031 [-0.043; -0.017])
AWR по доле	0.1633 (-0.0139 [-0.0158; -0.0119])	0.3317 (-0.0175 [-0.0213; -0.0136])	1.194 (-0.066 [-0.081; -0.050])
GRPO R6, β=1	0.1692 (-0.0080 [-0.0095; -0.0062])	0.3366 (-0.0127 [-0.0163; -0.0090])	1.256 (-0.004 [-0.018; +0.010])
GRPO R3, β=2	0.1746 (-0.0026 [-0.0039; -0.0013])	0.3441 (-0.0051 [-0.0082; -0.0023])	1.265 (+0.004 [-0.008; +0.016])
GRPO R7α, β=1	0.1771 (-0.0001 [-0.0012; +0.0010])	0.3489 (-0.0003 [-0.0022; +0.0018])	1.266 (+0.006 [-0.002; +0.014])
GRPO R8, β=2	0.1769 (-0.0003 [-0.0015; +0.0009])	0.3496 (+0.0004 [-0.0019; +0.0028])	1.270 (+0.010 [-0.000; +0.021])
GRPO R9, β=2	0.1771 (-0.0001 [-0.0012; +0.0011])	0.3500 (+0.0008 [-0.0014; +0.0030])	1.273 (+0.012 [+0.002; +0.022])
AWR по длительности, seed 1	0.1787 (+0.0015 [+0.0004; +0.0027])	0.3511 (+0.0019 [-0.0005; +0.0044])	1.292 (+0.032 [+0.022; +0.041])
AWR по длительности, seed 2	0.1786 (+0.0014 [+0.0002; +0.0026])	0.3518 (+0.0026 [-0.0001; +0.0050])	1.295 (+0.034 [+0.023; +0.044])
AWR по длительности, seed 3	0.1786 (+0.0014 [+0.0002; +0.0025])	0.3506 (+0.0014 [-0.0010; +0.0038])	1.291 (+0.031 [+0.021; +0.041])
AWR, досмотр > 50%	0.1686 (-0.0085 [-0.0100; -0.0069])	0.3406 (-0.0086 [-0.0119; -0.0050])	1.229 (-0.032 [-0.045; -0.017])
AWR, полный досмотр	0.1667 (-0.0105 [-0.0122; -0.0089])	0.3405 (-0.0087 [-0.0118; -0.0053])	1.222 (-0.038 [-0.050; -0.024])
AWR с V(s), γ=0.9	0.1696 (-0.0075 [-0.0089; -0.0062])	0.3418 (-0.0074 [-0.0102; -0.0044])	1.261 (+0.000 [-0.010; +0.011])
CRR γ=0, seed 1	0.1747 (-0.0025 [-0.0043; -0.0006])	0.3426 (-0.0066 [-0.0107; -0.0026])	1.325 (+0.064 [+0.048; +0.079])
CRR γ=0, seed 2	0.1747 (-0.0025 [-0.0042; -0.0007])	0.3437 (-0.0056 [-0.0095; -0.0014])	1.325 (+0.064 [+0.048; +0.080])
CRR γ=0, seed 3	0.1755 (-0.0017 [-0.0035; +0.0002])	0.3442 (-0.0050 [-0.0087; -0.0011])	1.327 (+0.067 [+0.051; +0.082])
CRR γ=0.5	0.1712 (-0.0060 [-0.0079; -0.0041])	0.3365 (-0.0128 [-0.0166; -0.0082])	1.310 (+0.050 [+0.032; +0.066])
CRR γ=0.9	0.1561 (-0.0211 [-0.0229; -0.0189])	0.3195 (-0.0297 [-0.0336; -0.0254])	1.226 (-0.034 [-0.051; -0.020])
CRR γ=0.9, β=2	0.1662 (-0.0110 [-0.0125; -0.0094])	0.3351 (-0.0142 [-0.0173; -0.0106])	1.256 (-0.005 [-0.017; +0.007])